

Домашнее задание. Практическая работа

Дисциплина ETL-процессы.

Тема Тема 9. Работа с big data и Тема 10. NoSQL в ETL-процессах.

Форма проверки

Домашнее задание с самопроверкой.

Совет: выполняйте его сразу, как только изучите тему.

Имя преподавателя

Артём Озерков.

Время выполнения

2 часа.

Цель задания

Практика работы с big data и NoSQL в облаке

Инструменты для выполнения ДЗ

Yandex Data Processing, Apache Hadoop, Apache Spark, Managed Service for Kafka, Yandex StoreDoc, Yandex Data Transfer

Правила приёма работы

Сделайте скриншот изначальных и изменённых данных. Прикрепите в LMS файл или ссылку на GitHub со скриншотами.

Важно:

- убедитесь, что доступ к материалам открыт;
- название файла должно содержать фамилию и имя студента, номер и название ДЗ.

Чек-лист самопроверки

Задание считается выполненным:

- если прикреплены файл с выполненным заданием или ссылка на GitHub;
- в файле или на GitHub содержится выполненное задание;
- доступ к материалам открыт.

Дедлайн

6 дней после открытия задания на платформе.

Описание задания

Повторите работу из демонстрации вебинаров.

- Вебинар «Работа с big data»
 1. Разверните кластер Hadoop и Spark с помощью Yandex Data Processing.
 2. Загрузите данные для обработки.
 3. Проведите трансформацию и запись в Yandex Data Processing.

- Вебинар «NoSQL в ETL-процессах» ([материалы демонстрации](#))

В кластер Yandex StoreDoc можно в реальном времени поставлять данные из топиков Apache Kafka®.

Чтобы запустить поставку данных:

1. Подготовьте тестовые данные.
2. Подготовьте и активируйте трансфер.
3. Проверьте работоспособность трансфера.

Удалите созданные ресурсы.